

Informe

Santiago Rocca, Maximiliano Fisz

Julio 2025

1 Introducción

Nuestro trabajo constara de intentar clasificar imágenes de diversos tipos de vehículos: autos, camionetas, bicicletas y motocicletas. Para ello, construimos distintos tipos de modelos utilizando las técnicas de detección de features y extracción de descriptores ORB (Oriented FAST and BRIEF) y SIFT, y Bag of Words con los métodos de clustering: KMeans y Kmedoids, utilizando en el segundo en particular el algoritmo CLARA. Estos distintos modelos fueron entrenados y evaluados en un mismo dataset.

2 Dataset

El dataset es un subconjunto de la unión de 3 datasets distintos de la plataforma Kaggle¹²³. En la cual existen las clases: auto, camioneta, bicicleta y motocicleta, cabe aclarar que cada clase posee una cantidad pseudo-proporcional de imágenes. Se partieron de 1204 imágenes las cuales debían poseer una de las clases, las cuales pueden estar rotadas, y ninguna otra; luego fueron separadas en dos grupos, entrenamiento y validación tomando un 20% para validar y 80% para entrenar.

3 Objetivos y motivaciones

El objetivo del proyecto fue comparar si ORB mejora la precisión para la clasificación de vehículos utilizando BOW con respecto a SIFT con BOW, uti-

lizando KMeans o KMedoids como métodos de *clustering*. Aunque SIFT suele ser una técnica muy robusta, tiene la desventaja no menor de ser código propietario: ¿Nos preguntamos, dependemos de SIFT o hay alternativas razonables?.

4 Metodologia

En primer lugar, se cargaron las imágenes del dataset y se realizaron los siguientes pasos de pre procesamiento: se convirtió cada imagen a escala de gris y se cambio el tamaño a 512×512 para reducir tiempos de computo sin perder tanta precisión en los modelos.

Se tomo la decision de evaluar ORB en diferentes cantidades de keypoints por cada imagen para la detección de features. Evaluamos con 100, 250, 500, 750 y 1000 keypoints. Por otro lado evaluamos SIFT sin limitar la cantidad de features extraídas.

Una vez se detectaron las features, se hizo *cross-validation* tomando 3 subsets del subset de entrenamiento. Se compararon los modelos utilizando *Bag of Words*, creando el vocabulario visual con los descriptores binarios de las features de *ORB* en primer lugar con *KMedoids* utilizando la metrica *hamming* por la buena definición espacio métrico ($\{0,1\}^+$, d_H) y su eficiencia. Además, siendo una practica común, evaluamos el descriptor binario como si lo fuera en KMeans con la métrica euclidiana. Finalmente, se hizo otro modelo para evaluar, con los descriptores de SIFT utilizamos Bag of Words con KMeans.

En el modelo con ORB, la complejidad de *KMeans* es $O(nkd)$ (a groso modo) siendo k la cantidad de clusters (palabras visuales), n la cantidad de vectores (descriptores de cada feature) y d la dimensión de cada vector (*ORB* en particular, devuelve una lista

¹Bicycle Image Dataset — Vehicle Dataset

²Car vs Bike Classification Dataset

³60,000+ Images of Cars

de vectores de tamaño fijo 256 por lo que $d = 256$); por lo tanto en nuestro problema para KMeans representa un complejidad final de $O(kd)$. Por otro lado *KMedoids* al ser un método de clustering mas robusto tiene una complejidad temporal mucho mayor la cual es $O(k(n - k)^2)$ en su implementación general, PAM. Además posee una complejidad espacial de $O(n^2)$. Veamos un ejemplo para entender las magnitudes que conlleva ir por esta ruta: por ejemplo, Si extrajáramos 1000 descriptores, típicamente de 4 bytes cada uno, a 1000 imágenes, eso requeriría una cantidad de memoria RAM de aproximadamente 16 terabytes; es por ello que se decidió usar la implementación CLARA, puesto que fija una cantidad de muestra de datos, en nuestro caso descriptores, reduciendo significativamente la complejidad espacial a $O(sd + kd)$ siendo s la cantidad de muestras. Obteniendo de esta manera un complejidad temporal final de $O(skn^2)$ y una espacial, la cual fijamos en la recomendación de los autores del algoritmo ⁴ logrando finalmente $O(k^2n^2)$. Es por ello que si bien KMedoids es mas robusto frente a datos *outliers* conlleva mas tiempo que KMeans.

Una vez construido el vocabulario visual, entrenamos un modelo *SVM* y evaluamos utilizando *cross-validation*.

Habiendo obtenidos los resultados de los modelos en el *cross-validation* tomamos los mejores modelos en términos de la métrica de exactitud y en caso de empate la métrica F_1 con los diferentes modelos.

Finalmente, a partir del subconjunto de entrenamiento y de evaluación del *dataset* se extrajeron las features con la técnica de cada modelo y se construye el vocabulario visual con los mejores parámetros. Por ultimo se entrena un modelo *SVM* y se evalúa su desempeño final..


5 Resultados

Al realizar *cross-validation* entre los distintos modelos se obtuvieron los siguientes resultados

1. ORB + BOW (con CLARA)

⁴los autores recomiendan $40 + 2k$



En cuanto a exactitud, se puede observar que los resultados de exactitud no varían, todos los valores se encuentran en el intervalo $(0.5, 0.6)$ siendo el promedio 0.527. Respecto a F_1 , sucede lo mismo que con la exactitud, resultados uniformes en el intervalo $(0.5, 0.6)$ con promedio 0.519. Los parámetros que se eligieron para el modelo final con esta técnica el de 300 palabras visuales y 250 keypoints, que logro una exactitud de 0.562.



2. ORB + BOW (con KMeans)

En cuanto a exactitud, se puede observar que los resultados de exactitud no varían mucho tampoco, todos los valores se encuentran en el intervalo $(0.5, 0.6)$. Sin embargo, se aprecia una mejora general de estos, en particular el promedio, que es de 0.556. Consiguiendo así una diferencia positiva pero no significativa respecto a los resultados del modelo 1. En

cuanto a $F1$, sucede lo mismo que la exactitud, resultados uniformes, con promedio 0.547 y la misma apreciación anterior que con los resultados del modelo 1. Los parámetros que se eligieron para el modelo 2 fueron el de 300 palabras visuales y 250 keypoints. que lograron una exactitud de 0.589.



En resumen los parámetros finales elegidos para cada modelo fueron:

Modelo	KeyPoints	Palabras visuales	Exactitud
ORB + CLARA	250	300	0.562
ORB + KMeans	250	300	0.589
SIFT + KMeans	-	300	0.706


3. SIFT + BOW (con KMeans)

Usando SIFT se observa que los valores varían más para la exactitud con un promedio de 0.659 y $F1$ 0.653, pero ambas métricas se encuentran en el intervalo (0.6, 0.7]. A diferencia del modelo 1 y modelo 2, se aprecia una diferencia significativa de 0.177 y 0.148 puntos en exactitud respectivamente. El parámetro que se eligió para el modelo 3 fue 300 palabras visuales que maximizo la exactitud con 0.706.


Una vez elegidos los modelos, los entrenamos con el subconjunto entero de entrenamiento y los evaluamos con el subconjunto de evaluación con una SVM. Los resultados de exactitud obtenidos para esta prueba final fueron los siguientes:

Modelo	Exactitud
ORB + CLARA	0.564
ORB + KMeans	0.645
SIFT + KMeans	0.692


SIFT + KMeans muestra una exactitud mayor a los otros modelos, sin embargo, la diferencia parece replicable. Además, se aprecia que al utilizar CLARA con d_H no se obtiene un mejor resultado que con la práctica usual de KMeans. En cuanto a las matrices de confusión se observa que todos los modelos poseen dificultad notable para diferenciar entre Auto, Camioneta y Motocicleta. El modelo que utiliza SIFT tiene más exactitud en promedio y comete menos frecuentemente este error, pero mostrando más claramente que el problema subyacente está entre las clases de Auto y Motocicleta.



ORB + CLARA



ORB + KMeans



SIFT + KMeans

6 Discussion

Finalmente resulta que el mejor modelo en estas pruebas fue SIFT + BOW (con KMeans), sin embargo, el modelo de ORB + BOW (con KMeans) obtuvo resultados comparables. Podría suceder que usando otro *dataset* este modelo obtenga mejores resultados. En cuanto al modelo de ORB + BOW (con CLARA), no se obtuvo buenos resultados y desempeñó moderadamente por debajo a sus competidores, se duda que con otro tipo de *dataset* se obtengan mejores resultados.

Los resultados no fueron los esperados, se creía que los modelos con el método de *clustering* CLARA con la métrica d_H , puesto que los descriptores son binarios, o KMeans iban a ser superiores. Se llega a la justificación de estos resultados ya que SIFT actúa de manera más robusta frente a cambios de iluminación, escala y rotación, mientras que ORB no funciona tan bien con los cambios de iluminación.

Algunas limitaciones de este trabajo fueron: utilizar un *dataset* acotado, considerado principalmente la exactitud como métrica principal, no realizado pruebas variando el tamaño de las imágenes, entre otras.

Ciertas mejoras podrían ser consideradas para obtener mejores resultados en el futuro: la ampliación del *dataset* y mejor curaduría de las imágenes, variación de los tamaños de estas. Otra metodología que se pudo haber aplicado que hubiera mejorado

consistentemente el estudio es la de en primer lugar clasificar por el numero de ejes, entre 2 y 4, y a partir de esa clasificación, dividir entre o bien auto o camioneta, o bien bicicleta o motocicleta.

En ningún momento se considero utilizar la transformación TF-DI puesto que penaliza características comunes que pueden ser importantes.

7 Conclusión

Los resultados experimentales indican que el uso de ORB como extractor de características no mejora significativamente la precisión del modelo Bag of Words en comparación con SIFT+BOW(con KMeans), tanto al emplear KMeans como CLARA como algoritmos de clustering; pero no lo elimina totalmente como alternativa de código abierto del ecosistema.